

Visual Computing

Niclas Kusenbach

LaTeX version:  SCHOUTER

Table of Contents

1 Einführung in Visual Computing	2	3.2.3 Prior und Likelihood in der Praxis	10
1.1 Grundlagen Visual Computing	2	3.3 Naive Bayes Klassifikator	10
1.2 Vier exemplarische Themenbereiche	2	3.3.1 Das Problem hoher Dimensionen .	10
1.3 Wichtige Konzepte und Begriffe	2	3.3.2 Naive Bayes Entscheidungsregel .	11
1.4 Empfohlene Literatur	2	3.4 Fallstudie: Gesichtsdetektion	11
1.5 Zusammenfassung	3	3.4.1 Sliding Window Ansatz	11
		3.5 Erkennungsarten (Biometrie)	12
2 Wahrnehmung (Perception)	4		
2.1 Motivation und Kognition (Motivation and Cognition)	4		
2.2 Das Visuelle System (The Visual System)	4		
2.2.1 Aufbau des Auges (Structure of the Eye)	4		
2.2.2 Photorezeptoren (Photoreceptors)	5		
2.3 Vorverarbeitung & Helligkeit (Preprocessing & Brightness)	6		
2.3.1 Signalverarbeitung in der Retina .	6		
2.3.2 Optische Täuschungen (Optical Illusions)	6		
2.3.3 Helligkeitswahrnehmung (Brightness Perception)	7		
2.3.4 Auflösung und Kontrast (Resolution and Contrast)	7		
2.4 Informationsextraktion: Tiefenwahrnehmung (Depth Perception)	7		
2.5 Aufmerksamkeit und Gedächtnis (Attention and Memory)	8		
3 Erkennung	9		
3.1 Das Problem der Objekterkennung	9		
3.1.1 Herausforderungen der Erkennung	9		
3.1.2 Intuition: Wie funktioniert Erkennung?	9		
3.2 Bayes Decision Theory (BDT)	9		
3.2.1 Bayes-Entscheidungsregel (Fehlerminimierung)	10		
3.2.2 Likelihood Ratio Test (Spezialfall 2 Klassen)	10		

1 Einführung in Visual Computing

1.1 Grundlagen Visual Computing

Definition

Visual Computing ist die Kombination mehrerer Informatikbereiche, die im Wesentlichen mit Bildern und Modellen arbeiten.

- Umfasst **Computergrafik**, **Computer Vision**, **Mensch-Maschine-Interaktion**, **Mustererkennung** und **Maschinelles Lernen**.
- Enge Verbindung zwischen Computer Vision und Computer Graphics – keine getrennte Betrachtung.
- Zentrale Fragestellungen: Informationsgewinnung aus Daten, effiziente Extraktion relevanter Information.

1.2 Vier exemplarische Themenbereiche

1. **3D Internet:** Erweiterung des Dokumentbegriffs auf 3D-Modelle; Anwendungen in Bildung, Medizin, Kultur.
 - 3D-Web, AR/VR, digitale Kulturgüter, Metaverse.
 - Retro-Digitalisierung vs. Digital Creation (CultLab3D, Flickr-Photogrammetrie).
2. **Skalierbare Objektmodellierung und -erkennung:**
 - Ziel: Erkennung zehntausender Kategorien mittels semantischer Hierarchien.
 - Nutzung von Deep Learning (Convolutional NNs, Transferlernen, 3D-Objektdatenbanken).
3. **Big Data / Visual Analytics:**
 - Kombination von Datenanalyse, ML und Visualisierung zur explorativen Erkenntnisgewinnung.
 - Verarbeitung großer heterogener Datenmengen (z. B. 300 000 Flickr-Bilder von Rom).
4. **Scene Understanding (3D/4D):**
 - Modellierung und Analyse von Szenen in Raum und Zeit.
 - Kombination von Objekterkennung, Tracking, Semantik und Bewegungsanalyse.
 - Anwendungen: Autonomes Fahren, Robotik, Sicherheitsüberwachung, AAL.

1.3 Wichtige Konzepte und Begriffe

- **Deep Learning / Convolutional Networks** – Grundprinzipien, GPU-basierte Berechnungen.
- **Interpretierbarkeit (White-Box vs. Black-Box)** – KI-Erklärbarkeit, Bias und Ethik.
- **Visualisierung und Informationsvisualisierung** – Darstellung komplexer Daten.
- **3D Output und AR/VR Technologien** – z. B. Shapeways, Wikitude.
- **Digitale Kultur und Erhalt von Kulturgütern** – z. B. Project Mosul, 3D-Rekonstruktionen.

1.4 Empfohlene Literatur

Autor / Titel	Relevanz
Szeliski – <i>Computer Vision: Algorithms and Applications</i>	Fundamentale Algorithmen zur Bildverarbeitung und -analyse.

Blundell – <i>An Introduction to Computer Graphics</i>	Grundlagen der 3D-Darstellung.
Dix et al. – <i>Human Computer Interaction</i>	Basis für Mensch-Maschine-Schnittstellen.
Burger & Burke – <i>Digitale Bildverarbeitung – algorithmische Einführung</i>	Mathematische Grundlagen für Bildverarbeitung.

1.5 Zusammenfassung

- Visual Computing verbindet Grafik, Vision und Interaktion.
- Vier Kernbereiche (3D Internet, Objekterkennung, Visual Analytics, Scene Understanding) bilden die strukturierte Grundlage der Vorlesung und sind klausurrelevant.
- Verständnis der praktischen Beispiele und Übungen ist essentiell für die Klausur.

2 Wahrnehmung (Perception)

2.1 Motivation und Kognition (Motivation and Cognition)

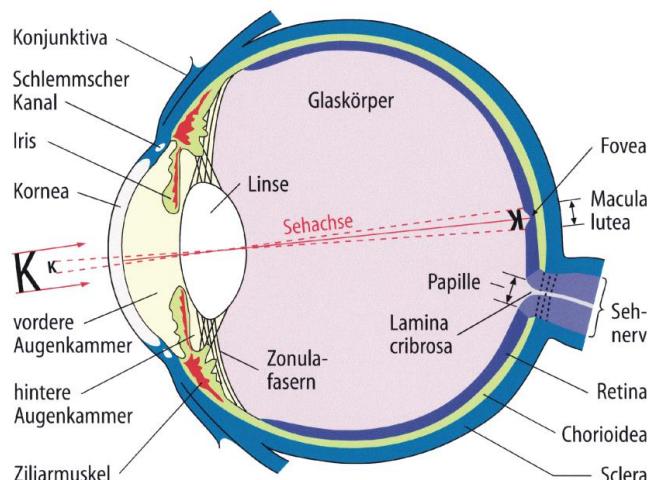
- **Warum VC? (Why VC?)** Die Leistungsfähigkeit von Rechnern wächst exponentiell (**Moore's Law**), aber die Kapazität von Menschen ist (fast) konstant (**Darwin's Law**). VC hilft, diese Lücke zu überbrücken.
- **Kognition (Cognition):** Sammelbegriff für alle Prozesse des Wahrnehmens und Erkennens (Denken, Erinnern, Lernen, etc.).
- **Modell der Informationsverarbeitung (Model of Information Processing):** Ein modulares 3-Stufenmodell:
 1. **Perception** (Wahrnehmung durch Sinne)
 2. **Decision** (Entscheidungsfindung im Gehirn)
 3. **Response** (Reaktion durch Körper)
- **Bearbeitungszeiten (Processing Times):** Jedes Untersystem benötigt Zeit.
 - Wahrnehmung (Perception): ≈ 100 ms
 - Entscheidung (Cognition): ≈ 70 ms
 - Reaktion (Motor): ≈ 70 ms
- **Wahrnehmung vs. Realität:** Was wir wahrnehmen, ist kein direktes Abbild der Realität, sondern eine partielle Hypothese, die auf unvollständiger Information basiert.

2.2 Das Visuelle System (The Visual System)

Visueller Reiz (Visual Stimulus)

Ein äußerer visueller Reiz ist **elektromagnetische Strahlung**. Sichtbares Licht liegt im Wellenlängenbereich von ca. 400nm (violett) bis 700nm (rot). Die Frequenz v und Wellenlänge λ hängen über $v \cdot \lambda = c$ zusammen.

2.2.1 Aufbau des Auges (Structure of the Eye)



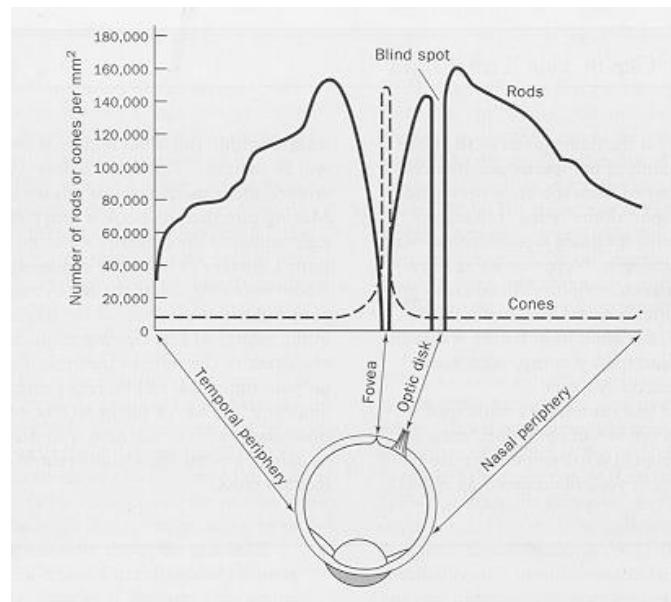
- **Optische Elemente:** Hornhaut (Kornea), Linse, Iris (Blende, 2-8mm), Glaskörper.

- **Linse (Lens):** Akkommodation (Scharfeinstellung).
- **Retina (Netzhaut):** Enthält die Photorezeptoren.
- **Fovea Centralis:** Bereich der höchsten Auflösung (im "gelben Fleck" / Macula lutea).
- **Blinder Fleck (Blind Spot):** Papilla nervi optici; Austrittspunkt des Sehnervs, keine Rezeptoren.

2.2.2 Photorezeptoren (Photoreceptors)

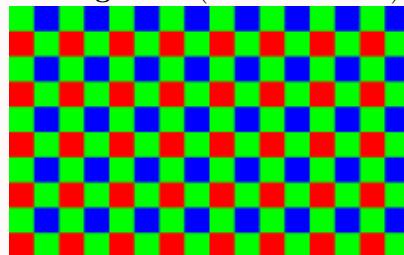
Es gibt zwei Haupttypen von Photorezeptoren auf der Retina:

- **Stäbchen (Rods):**
 - ca. 100-120 Mio.
 - Hauptsächlich außerhalb der Fovea.
 - Für **Nachtsehen (skotopisches Sehen)**.
 - Sehr lichtempfindlich, kein Farbsehen.
 - Empfindlichkeitsmaximum bei 498 nm (grün).
- **Zapfen (Cones):**
 - ca. 7-8 Mio.
 - Hauptsächlich **in der Fovea** (Bereich des schärfsten Sehens).
 - Für **Tagsehen (photopisches Sehen)**.
 - 3 Typen für Farbsehen:
 - * **S-Zapfen** (Short): Max. bei 420 nm (Blau).
 - * **M-Zapfen** (Medium): Max. bei 534 nm (Grün).
 - * **L-Zapfen** (Long): Max. bei 564 nm (Rot).



Bayer-Sensor

Digitale Kamerasensoren nutzen oft ein **Bayer-Muster**. Dies ist ein Farbfilter-Array, meist mit **50% Grün, 25% Rot und 25% Blau**. Grün ist privilegiert, da das menschliche Auge für Grün den größten Beitrag zur Helligkeits- und Kontrastwahrnehmung leistet (72% Grünanteil).

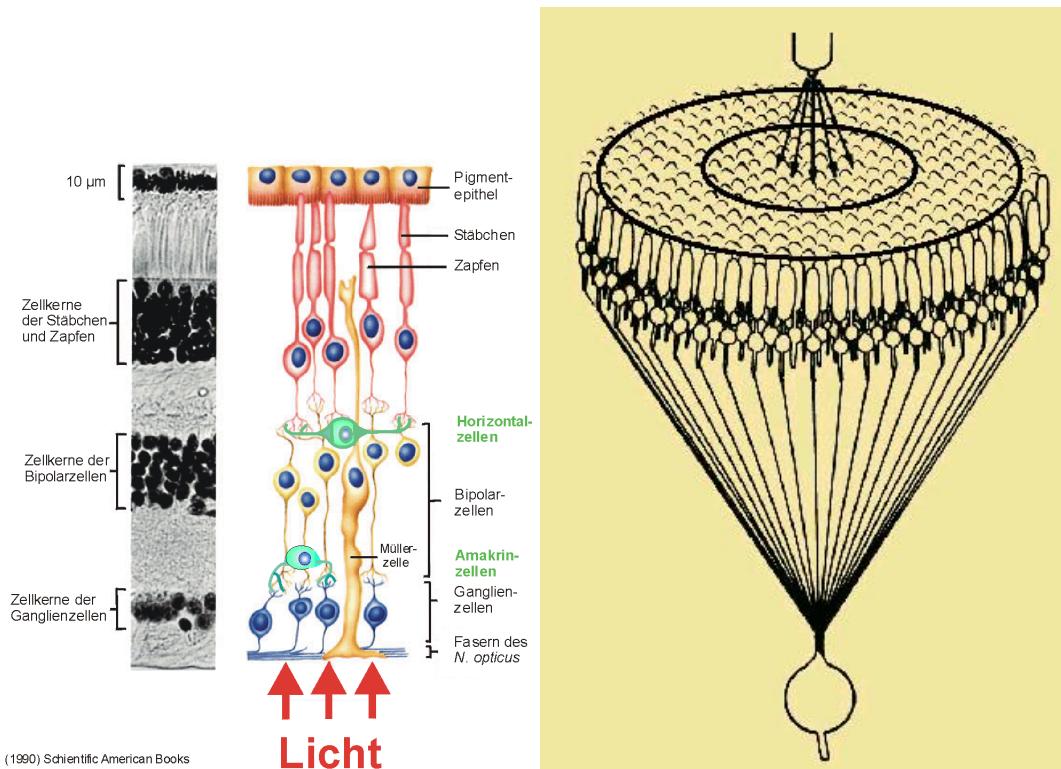


2.3 Vorverarbeitung & Helligkeit (Preprocessing & Brightness)

2.3.1 Signalverarbeitung in der Retina

Das Licht trifft (paradoxerweise) erst auf die Ganglien- und Bipolarzellen, bevor es die Stäbchen und Zapfen erreicht.

- **Bipolar-Zellen:** Sammeln, gewichten und leiten Informationen weiter.
- **Horizontal- & Amakrin-Zellen:** Kombinieren Signale mehrerer Rezeptoren (räumlich) bzw. verarbeiten zeitliche Änderungen.
- **Ganglien-Zellen:** Integrieren Informationen, z.B. für **Kontrastwahrnehmung** durch Unterschied zwischen Zentrum und Peripherie (Center-Surround-Antagonismus).



2.3.2 Optische Täuschungen (Optical Illusions)

Diese frühe Signalverarbeitung führt zu Täuschungen, die zeigen, dass Wahrnehmung nicht objektiv ist:

- **Hermann-Gitter:** Graue Flecke erscheinen in den Kreuzungen eines weißen Gitters auf schwarzem Grund.

- **Mach-Bänder (Mach Bands):** An Kanten zwischen unterschiedlich hellen, aber homogenen Flächen werden helle/dunkle Bänder wahrgenommen, wo keine sind (eine Art "Überschwingen" der Wahrnehmung).
- **Simultankontrast (Simultaneous Contrast):** Die wahrgenommene Helligkeit einer Fläche hängt von der Helligkeit ihrer Umgebung ab. Ein identisches Grau erscheint auf schwarzem Grund heller als auf weißem Grund.

2.3.3 Helligkeitswahrnehmung (Brightness Perception)

- Helligkeit (Brightness) ist **keine absolute Größe**, sondern subjektiv.
- Sie ist u.a. abhängig von der Reizstärke (Leuchtdichte), der Adaption an vorherige Leuchtdichten und der Umgebungsleuchtdichte.
- **Weber-Fechnersches Gesetz:** Beschreibt den Zusammenhang zwischen Reizintensität (R) und Hellemmpfindung (L).
 - **Webersches Gesetz (Schwelle):** $\Delta L = \frac{\Delta R}{R} = const.$ (minimaler Kontrast für Wahrnehmung ca. 0.8%)
 - **Fechnersches Gesetz:** $L = c_1 \times \log R$
 - **Stevensches Gesetz (State-of-the-Art):** $E = c_2 \times R^k$ (für Licht $k = 0.3$)

2.3.4 Auflösung und Kontrast (Resolution and Contrast)

- **Sehschärfe (Visual Acuity):** Die Fähigkeit, kleine Details zu erkennen, ist begrenzt. Z.B. Punktsehschärfe ca. 1 Bogenminute ($1'$).
- **Kontrastempfindlichkeit (Contrast Sensitivity):** Gemessen mit Sinus-Mustern (sinusoidal gratings).
- **Contrast Sensitivity Function (CSF):** Beschreibt die Auflösung im Frequenzraum. Zeigt, dass das Auge für mittlere Ortsfrequenzen (ca. 2-5 Zyklen/Grad) am empfindlichsten ist und die Empfindlichkeit zu sehr hohen (Details) und sehr niedrigen Frequenzen (langsame Übergänge) abfällt.

2.4 Informationsextraktion: Tiefenwahrnehmung (Depth Perception)

Das visuelle System nutzt verschiedene Hinweisreize (**Depth Cues**), um Raumwahrnehmung zu erzeugen.

- **1. Binokulare Cues (Zwei Augen):**
 - **Disparität / Parallaxe:** Der Haupt-Cue. Da die Augen getrennt sind, sehen sie leicht unterschiedliche Bilder. Das Gehirn fusioniert diese.
 - **Positive Parallaxe:** Objekte erscheinen *hinter* der Bildebene.
 - **Negative Parallaxe:** Objekte erscheinen *vor* der Bildebene.
 - **Akkomodation** (Linsenanpassung) und **Konvergenz** (Augenstellung).
- **2. Pictorial Depth Cues (Monokular / Bildlich):**
 - **Linearperspektive:** Parallele Linien konvergieren in der Ferne.
 - **Verdeckung (Occlusion):** Ein Objekt, das ein anderes verdeckt, wird als näher wahrgenommen.
 - **Texturgradient:** Texturen werden mit der Entfernung dichter und feiner.
 - **Atmosphärische Tiefe:** Entfernte Objekte erscheinen blasser und bläulicher.
 - **Schattenwurf (Shadows):** Wichtig für Position und Form; Annahme: Licht kommt von oben.
 - Weitere: Fokus/Blur, Vertraute Größe, Höhe im Gesichtsfeld, etc..
- **3. Dynamische Depth Cues (Bewegung):**
 - **Bewegungsparallaxe (Motion Parallax):** Objekte, die näher sind, bewegen sich bei einer Kopfbewegung scheinbar schneller als entfernte Objekte.

- **Kinetischer Tiefeneffekt (Kinetic Depth Effect):** 3D-Struktur wird aus der 2D-Projektion einer Bewegung extrahiert (z.B. "Structure from Motion").

Die Depth Cues sind nicht redundant, sondern **additiv** und werden je nach Aufgabe (Task) **flexibel gewichtet**.

2.5 Aufmerksamkeit und Gedächtnis (Attention and Memory)

- **Frühe Wahrnehmung (Preattentive Processing):** Bestimmte Merkmale (Farbe, Größe, Richtung, Schattierung) werden sehr schnell (ca. 10 ms) und parallel verarbeitet, bevor die bewusste Aufmerksamkeit greift. **Verbindungen** von Merkmalen (z.B. "roter Kreis") erfordern Aufmerksamkeit.
- **Aufmerksamkeit (Attention):** Dient als **Filter** oder "Gateway to Memory".
- **Veränderungsblindheit (Change Blindness):** Unfähigkeit, große Änderungen in einer Szene zu bemerken, wenn die Aufmerksamkeit abgelenkt ist (z.B. durch Flimmern). Dies zeigt, dass wir kein vollständiges Bild der Welt im Kopf haben.
- **Arbeitsgedächtnis (Working Memory):**
 - Schneller Zugriff (ca. 70 ms), schneller Verfall (ca. 200 ms).
 - Sehr begrenzte Kapazität: 7 ± 2 "Chunks" (Miller, 1956).
 - "Chunks" sind sinnvolle Einheiten (z.B. DA, TU, VC, VL statt DATUVCVL).
- **Langzeitgedächtnis (Long-term Memory):**
 - Nahezu unbegrenzte Kapazität.
 - Langsamerer Zugriff (ca. 100 ms).

3 Erkennung

3.1 Das Problem der Objekterkennung

3.1.1 Herausforderungen der Erkennung

Menschliche Wahrnehmung ist Computern weit überlegen. Die Erkennung ist schwierig aufgrund von:

- **Mehrdeutigkeit & Illusionen:** (z.B. Don Quixote-Gesicht, Mona Lisa-Mosaik, ambivalente Elefantenbeine).
- **Tarnung & Verdeckung:** (z.B. Bev Doolittles Pferde im Schnee).
- **Kontext:** Die Interpretation von Teilen hängt stark vom Gesamtkontext ab (z.B. verschwommene Straßenszene, Punktwolken-Wörter).
- **Fehler im Kontext:** M.C. Escher-Bilder sind *lokal* konsistent, aber *global* unmöglich.

3.1.2 Intuition: Wie funktioniert Erkennung?

Objekterkennung basiert auf zwei Hauptkomponenten:

1. **Lokale Beschreibung / Merkmale:** (z.B. Augen, Nase, Mund bei einem Gesicht).
2. **Globale Anordnung der Merkmale:** (z.B. relative Positionen und Größen der Merkmale zueinander).

Weitere wichtige Aspekte sind Segmentierung und Szenenkontext.

Pictorial Structure (Fischler & Elschlager, 1973) Ein klassisches Modell zur Objekterkennung, das diese Intuition formalisiert.

- **Teile (Parts):** 2D-Bildfragmente (lokale Merkmale).
- **Aufbau (Structure):** Die Anordnung der Teile, oft modelliert durch "Federn", die die relative Position und Deformation beschränken.

Herausforderungen für dieses Modell sind **Deformationen** (Teile ändern ihre Position) und **Durcheinander** (Clutter, irrelevante Merkmale im Hintergrund).

3.2 Bayes Decision Theory (BDT)

Die BDT ist ein mathematisches Framework zur optimalen Entscheidungsfindung unter Unsicherheit. Ihr Ziel ist es, Klassifikationsentscheidungen so zu treffen, dass die **erwartete Fehlklassifikationsrate minimiert** wird. Sie nutzt dazu Wahrscheinlichkeiten als formale Beschreibung von Unsicherheit.

Die drei Kernkonzepte der BDT

1. **A Priori (Prior)** $P(C_k)$: Die Wahrscheinlichkeit einer Klasse C_k , *bevor* wir Daten x beobachtet haben. Der Prior kodiert unser Vorwissen oder unsere Erwartungen über die Häufigkeit von Klassen. Wichtig: Priors wirken wie ein "Bias" zugunsten bestimmter Klassen.
2. **Klassenspezifische Dichte (Likelihood)** $p(x|C_k)$: Die Wahrscheinlichkeit (genauer: Wahrscheinlichkeitsdichte), die Merkmalsausprägung x zu beobachten, *unter der Annahme*, dass die wahre Klasse C_k ist. Sie beschreibt also, wie typisch ein bestimmtes Datenmuster x für eine Klasse ist. Hinweis: Likelihood ist eine Funktion in x , nicht in der Klasse.
3. **A Posteriori (Posterior)** $P(C_k|x)$: Nachbeobachtete Wahrscheinlichkeit einer Klasse, *nachdem* wir x kennen. Dies ist genau die Größe, die wir für die eigentliche Entscheidung benötigen.

Bayes' Theorem (Verbindung der Konzepte)

$$P(C_k|x) = \frac{p(x|C_k) P(C_k)}{p(x)}$$

Die Evidenz

$$p(x) = \sum_j p(x|C_j) P(C_j)$$

stellt sicher, dass die Posterior-Wahrscheinlichkeiten normiert sind. Wichtig: Für die Entscheidung ist $p(x)$ oft irrelevant, da es für alle Klassen gleich ist.

$$\text{Posterior} = \frac{\text{Likelihood} \times \text{Prior}}{\text{Evidenz}}$$

3.2.1 Bayes-Entscheidungsregel (Fehlerminimierung)

Wir wählen die Klasse mit der größten posterioren Wahrscheinlichkeit:

$$C^*(x) = \arg \max_k P(C_k|x).$$

Da der Nenner $p(x)$ konstant ist, genügt:

$$C^*(x) = \arg \max_k p(x|C_k) P(C_k).$$

Intuition: Die Likelihood misst, wie gut die Daten zu einer Klasse passen; der Prior berücksichtigt, wie plausibel diese Klasse im Voraus ist. Der Schnittpunkt der Produkte $p(x|C_k)P(C_k)$ bildet die **Entscheidungsgrenze**.

3.2.2 Likelihood Ratio Test (Spezialfall 2 Klassen)

Für zwei Klassen C_1 und C_2 :

$$\text{Entscheide } C_1 \text{ wenn: } \frac{p(x|C_1)}{p(x|C_2)} > \frac{P(C_2)}{P(C_1)}.$$

Links: datengetriebene Evidenz, Rechts: Schwellwert aus Vorwissen. So sieht man explizit, wie ein starker Prior eine Entscheidung "umkippen" kann.

3.2.3 Prior und Likelihood in der Praxis

Die Trennung zwischen Datenmodell (Likelihood) und Vorwissen (Prior) ermöglicht robuste Modelle:

- **Spracherkennung:** Likelihood = akustisches Modell; Prior = Sprachmodell. Das Sprachmodell zieht uns aus akustischen Mehrdeutigkeiten heraus.
- **Bildverarbeitung:** Likelihood = Appearance Model; Prior = Kontextwissen über sinnvolle Objekte am Ort.

3.3 Naive Bayes Klassifikator

3.3.1 Das Problem hoher Dimensionen

Für d Merkmale:

$$x = (x_1, \dots, x_d)$$

müssten wir die gemeinsame Dichte $p(x|C_k)$ im d -dimensionalen Raum schätzen. Dies benötigt exponentiell viele Daten: **Fluch der Dimensionalität**. Schon wenige Dutzend Dimensionen machen klassische Dichteschätzung praktisch unmöglich.

Die Naive-Unabhängigkeitssannahme Um das Problem zu umgehen, wird angenommen:

$$p(x|C_k) = p(x_1, \dots, x_d|C_k) \approx \prod_{i=1}^d p(x_i|C_k).$$

Das heißt: Die Merkmale sind *bedingt unabhängig* gegeben die Klasse. Diese Annahme ist oft falsch, aber in vielen Anwendungen erstaunlich effektiv, weil:

- Abhängigkeiten zwischen Merkmalen sich teilweise gegenseitig ausgleichen,
- Die Entscheidung meist nur eine Rangordnung braucht (MAP), nicht exakte Wahrscheinlichkeiten.

3.3.2 Naive Bayes Entscheidungsregel

Durch Einsetzen der Zerlegung:

$$C^*(x) = \arg \max_k P(C_k) \prod_{i=1}^d p(x_i|C_k).$$

Lernen bedeutet:

1. Schätzen der Priors $P(C_k)$ (Häufigkeiten).
2. Schätzen der eindimensionalen Dichten $p(x_i|C_k)$ für alle Merkmale und Klassen.

Log-Space (Numerische Stabilität) Da Produkte kleiner Wahrscheinlichkeiten numerisch instabil sind:

$$C^*(x) = \arg \max_k \left[\log P(C_k) + \sum_{i=1}^d \log p(x_i|C_k) \right].$$

Logarithmen ersetzen Multiplikationen durch Additionen, ohne die Entscheidung zu verändern.

3.4 Fallstudie: Gesichtsdetektion

Ein Beispiel für **Appearance-Based Methods**: Modelle werden direkt aus (großen) Bilddatensammlungen gelernt.

3.4.1 Sliding Window Ansatz

- Ein Fenster (z.B. 19×19 Pixel) wird über das gesamte Bild geschoben.
- Bei jeder Position wird entschieden: "Gesicht" (C_1) oder "Kein Gesicht" (C_2).
- Das Bild wird skaliert (z.B. Faktor 1.2 verkleinert) und der Vorgang wiederholt sich, um Gesichter aller Größen zu finden.

Fallstudie: Schneiderman & Kanade (1998) Ein sehr erfolgreicher Gesichtdetektor, der auf Naive Bayes basiert.

- **1. Repräsentation (Merkmale x_i): Wavelet-Koeffizienten** an bestimmten Frequenzen, Orientierungen und **Positionen** (f_i, u_i, v_i). Dies kodiert sowohl lokale Merkmale (Kanten) als auch deren globale Anordnung (Position).
- **2. Trainingsdaten:**
 - *Positive Beispiele* (C_1): Tausende von Bildern, die Gesichter enthalten (normalisiert).
 - *Negative Beispiele* (C_2): Tausende von Bildern, die *keine* Gesichter enthalten.
- **3. Klassifikator & Lernen:** Naive Bayes. Das "Lernen" besteht darin, die Wahrscheinlichkeiten $P(x_i|C_{\text{face}})$ und $P(x_i|C_{\text{non-face}})$ für jedes Merkmal x_i zu schätzen. Dies geschieht durch **Zählen (Erstellen von Histogrammen)** in den positiven und negativen Trainingsdatensätzen.
- **Multi-View:** Um Gesichter aus verschiedenen Winkeln zu erkennen, werden separate Detektoren trainiert (z.B. Frontal, Linksprofil, Rechtsprofil) und die Ergebnisse kombiniert.

3.5 Erkennungsarten (Biometrie)

Gesichtserkennung ist ein biometrisches Verfahren. Man muss zwischen verschiedenen Aufgaben unterscheiden:

- **Detektion:** (Face vs. Non-Face) Ist überhaupt ein Objekt (Gesicht) vorhanden?
- **Verifikation (1:1):** "Bin ich das?" (z.B. Smartphone entsperren).
 - Eine Person gibt ihre Identität an (z.B. Nutzer-ID).
 - Das System vergleicht die aktuelle Probe **nur mit dem einen** gespeicherten Template dieser ID.
 - Ausgabe: Ja / Nein.
- **Identifikation (1:n):** "Wer ist das?" (z.B. Überwachung).
 - Eine Person zeigt nur ihr Merkmal (Gesicht).
 - Das System vergleicht die Probe mit **allen n** Templates in der Datenbank.
 - Ausgabe: Eine Kandidatenliste (die m besten Treffer, $m \ll n$).